

Участник 2

Boosting, признаки и архитектура CatBoost

Доп. тюнинг CatBoost · основной sweep по MAE · LightGBM · каскад · Ridge ·
прогноз длительности игровой сессии (без API)

Таргет: target_next_session_length_sec · выборка 30000 строк (70/15/15) ·
CatBoost 1.2.10

Anti-leak: PASS · Chronology: PASS · No-NaN: PASS

1. Методология


Все эксперименты используют общий командный пайплайн (preprocessing/preprocessing.py): строго временное разбиение 70/15/15 (shuffle=False), единый anti-leak (удаление target*, future_*, ID и служебных временных колонок) и единый набор метрик из team_modeling_protocol.txt. Выбор конфигурации — только по validation; test используется один раз для финальной оценки.

Параметр	Значение
Выборка (последние по времени)	30000 строк
Train / Val / Test	21000 / 4500 / 4500
Признаков (числовых / категор.)	73 (59 / 14)
Train период	2026-04-27 21:34:36 → 2026-04-29 23:13:26
Test период	2026-04-30 11:32:42 → 2026-04-30 22:57:22
Базовый конфиг	depth=6, lr=0.05, l2=3.0, iters=800, target_mode=p995
Базовый val MAE / test MAE	522.5 / 429.3 сек

⚠ Важно: для next-session таргета MAE по validation у всех конфигов лежит в узком коридоре ~521-525 сек — таргет очень шумный ($R^2 \approx 0.01$, что отмечено в протоколе). Поэтому выигрыш архитектурных правок по MAE невелик, и их главная ценность — компактность и скорость модели.

2. SHAP feature selection vs ручной top-k

Встроенный рекурсивный отбор RecursiveByShapValues сравнивается с ручным top-k по важности. Вывод: SHAP-отбор на 40 признаках (из 73) даёт лучший val MAE (521.6), обходя и полную модель (522.5), и ручной top-k (523.3), при этом модель в ~3.5 раза меньше (199 КБ против 712 КБ). Размер модели можно сократить и ускорить inference без потери качества.



модель	отбор	k	val MAE	test MAE	fit, с	размер, КБ
shap_k40	shap_recursive	40	521.6	428.8	1.6	199
shap_k60	shap_recursive	60	521.8	429.2	4.0	763
full	none	73	522.5	429.3	3.9	712
topk_40	manual_topk	40	523.3	429.5	2.1	265
topk_60	manual_topk	60	523.3	429.8	2.8	475


3. Bootstrap: MVS vs Bernoulli / Bayesian

Minimal Variance Sampling добавлен к сравнению с Bernoulli и Bayesian; устойчивость измерена по сидам 42/52/62. Вывод: MVS не даёт выигрыша по MAE и не ускоряет заметно обучение; самый стабильный по сидам — Bayesian (std 0.18). Для long-tail (val_long_mae) различия в пределах шума.

конфиг	val MAE	$\pm$ std	test MAE	long MAE	fit, c
mvs_ss0.9	523.2	0.4	429.0	1967.0	3.3
bernoulli_ss0.8	523.2	0.7	428.6	1955.3	3.8
mvs_ss0.7	523.3	0.3	429.3	1962.0	3.2
bayesian	523.4	0.2	428.9	1963.2	3.6
mvs_ss0.8	523.9	1.1	429.4	1981.0	2.6

4. CTR-тюнинг категориальных признаков

Сетка по one_hot_max_size, max_ctr_complexity, ctr_target_border_count. Вывод: лучший — простой one_hot=10, ctr_complexity=1, ctr_border=1 (522.7). Комбинации категорий (mcc=2) и более тонкая квантизация таргета для CTR пользы не дают и раздувают модель (до 733 КБ). Топ-10 по val MAE:




конфиг	val MAE	test MAE	fit, с	размер, КБ
ohms10_mcc1_ctbc1	522.7	429.0	1.5	339
ohms10_mcc2_ctbc5	522.9	429.1	4.9	733
ohms10_mcc2_ctbc3	523.0	429.1	3.1	531
ohms5_mcc1_ctbc3	523.2	428.3	2.1	263
ohms10_mcc2_ctbc1	523.3	428.7	1.7	342
ohms2_mcc1_ctbc1	523.3	428.5	1.4	193
ohms2_mcc2_ctbc5	523.4	428.1	8.0	662
ohms5_mcc2_ctbc5	523.4	429.0	5.2	574
ohms2_mcc1_ctbc3	523.4	428.4	2.4	243
ohms10_mcc1_ctbc5	523.5	429.1	1.9	276

5. Структура деревьев: Symmetric / Depthwise / Lossguide

Сравнение стандартных симметричных деревьев с гибкими Depthwise и Lossguide. Вывод (главная находка): Depthwise, min_data_in_leaf=20 — лучший val MAE (522.3) и лучший long_mae (1943), при этом модель вдвое меньше и быстрее симметричной (359 КБ / 2.0 с против 712 КБ / 4.0 с). Гибкие деревья дают небольшое преимущество на неоднородных сегментах.

Структура деревьев: Depthwise (синий) vs Symmetric (оранж.) vs Lossguide (серый)



конфиг	val MAE	test MAE	small	normal	long	fit, c	КБ
depthwise_md120	522.3	428.9	215.1	316.1	1943.1	2.0	359
depthwise_md150	522.5	428.5	205.0	320.6	1966.3	1.6	259
lossguide_ml63_md120	522.5	429.0	207.0	320.1	1961.3	3.1	401
lossguide_ml127_md120	522.5	429.0	207.0	320.1	1961.3	2.9	401
symmetric	522.5	429.3	207.5	322.1	1955.5	4.0	712
lossguide_ml31_md150	523.4	428.4	205.7	320.0	1971.4	1.7	173
lossguide_ml63_md150	523.6	428.3	214.7	314.0	1957.3	2.0	221
lossguide_ml127_md150	523.6	428.3	214.7	314.0	1957.3	1.8	221
depthwise_md1100	523.8	428.7	204.8	316.5	1984.6	1.2	157
lossguide_ml31_md120	523.8	427.7	205.6	322.2	1969.9	2.1	242

6. Квантизация числовых признаков

Сетка по border_count и feature_border_type плюс per_float_feature_quantization на топ-3 числовых признаках. Вывод: дефолтный border_count=254, GreedyLogSum оптимален по val MAE; очень тонкая квантизация (512, per_float=1024) на длинном хвосте практически не помогает. Топ-10 по val MAE:

конфиг	val MAE	test MAE	long MAE	fit, c	КБ
bc254_GreedyLogSum	522.5	429.3	1955.5	3.7	712
bc254_Median	522.7	428.5	1958.8	3.4	713
bc128_Median	523.0	429.0	1960.2	3.4	651
bc254_UniformAndQuantiles	523.0	428.1	1964.6	2.4	493
bc64_GreedyLogSum	523.1	428.6	1963.9	5.0	825
bc128_GreedyLogSum	523.1	429.8	1959.1	4.5	772
bc64_Median	523.4	428.2	1966.5	3.7	670
bc64_UniformAndQuantiles	523.5	428.0	1964.4	3.9	756
bc512_GreedyLogSum	523.8	430.6	1951.3	2.7	461
per_float_top3_1024	523.8	429.0	1966.6	2.9	509


7. Запасной эксперимент: rsm

Случайный выбор доли признаков при поиске split ($rsm = 0.6 / 0.8 / 1.0$). Вывод: разрыв val-test практически одинаков ($\sim +93$ сек) для всех значений — дополнительной регуляризации rsm здесь не даёт; полезен скорее для разнообразия моделей в ансамбле.

rsm	val MAE	test MAE	fit, c
rsm1.0	522.5	429.3	3.9
rsm0.6	522.9	428.5	3.1
rsm0.8	523.7	428.4	2.1

8. Протокольные стратегии на лучшем конфиге (оба таргета)


Согласно протоколу §15, для лучшего конфига прогнаны три канонические стратегии — capped_target (MAE), Quantile:alpha=0.40 и Quantile:alpha=0.35 — на обоих таргетах. Вывод: capped_target лучший по общему MAE, а Quantile 0.35 — лучшая short-risk модель (минимальные ProductMAE/EngagementRiskMAE/small_mae). Это подтверждает командные результаты. CRM-таргет заметно стабильнее next-session (test MAE ~272 против ~429).



таргет	стратегия	loss	val MAE	Product	EngRisk	small	test M
target_next_session_length_sec	capped_target	MAE	522.5	251.6	261.9	207.5	429
target_next_session_length_sec	quantile_040	Quantile:alpha=0.40	529.2	233.6	242.7	158.7	43
target_next_session_length_sec	quantile_035	Quantile:alpha=0.35	539.7	221.0	230.4	117.7	43
future_sessions_mean_playtime_7d	capped_target	MAE	240.0	187.5	190.8	216.9	27
future_sessions_mean_playtime_7d	quantile_040	Quantile:alpha=0.40	238.1	173.8	177.7	176.4	27
future_sessions_mean_playtime_7d	quantile_035	Quantile:alpha=0.35	244.5	172.3	176.0	157.6	27

Часть II. Технический прогноз: основной CatBoost, LightGBM, каскад

Эксперименты из второго ТЗ (`distribution\_of\_responsibilities.txt`): поиск лучшей технической модели по validation MAE, сравнение групп признаков, альтернативный бустинг и более сложные архитектуры на базе CatBoost. API в объём не входит.



Главный вывод части II: CatBoost — лучшая техническая модель по val MAE; LightGBM сопоставим, но чуть хуже; линейный Ridge не обходит даже median-baseline. Это эмпирически обосновывает выбор CatBoost.


9. Основной CatBoost sweep по MAE (best_by_mae)

Широкий случайный поиск (40 конфигов) по сетке T3: iterations / depth / lr / l2 / min_data_in_leaf / random_strength / bootstrap / target_transform / clip_mode. Вывод: лучшая техническая модель — depth=7, lr=0.03, l2=5, log1p_p995, Bernoulli (val MAE 521.8, test 428.4). Полный sweep дал лишь ~0.7 сек к компактному базовому — снова упёрлись в шум таргета. Топ-8 по val MAE:

cfg	depth	lr	l2	iters	bootstrap	t_mode	clip	val	test
cfg39	7	0.0	5.0	1200	Bernoulli	log1p_p995	none	521.8	428.4
cfg06	8	0.0	10.0	1200	Bayesian	log1p_p995	none	522.1	427.2
cfg25	6	0.0	3.0	1500	Bernoulli	log1p_p995	p005_p995	522.5	428.2
cfg24	5	0.0	3.0	1500	Bernoulli	log1p_p995	p005_p995	522.6	427.8
cfg21	5	0.1	10.0	1200	Bayesian	log1p_p995	none	522.6	428.3
cfg33	5	0.0	5.0	1500	Bernoulli	log1p_p995	none	522.7	428.1
cfg16	8	0.0	5.0	1200	Bernoulli	log1p_p995	p005_p995	522.8	427.7
cfg01	8	0.0	3.0	1800	Bernoulli	p995	none	522.8	428.8

10. Feature ablation групп признаков


Наборы: session_only / session_install / session_install_events (полный) / top_k_40/60/73. Вывод: event-признаки почти не помогают — session_only (37 призна.) даёт val MAE 522.9 против 522.5 у полного набора (73), но модель в ~4 раза меньше (172 КБ vs 712 КБ) и обучается в ~8 раз быстрее. Для inference event-группу можно отбрасывать почти без потерь.



набор	k	val MAE	test MAE	fit, с	размер, КБ
session_install_events	73	522.5	429.3	3.9	712
session_install	58	522.9	429.1	3.7	556
session_only	37	522.9	428.4	0.5	172
top_k_73	73	523.0	429.0	2.9	506
top_k_40	40	523.3	429.5	2.1	265
top_k_60	60	523.3	429.8	2.8	475

11. Каскад «классификация → регрессия» (hard / soft / hybrid)

CatBoostClassifier (small/normal/long, acc≈0.51) + 3 посегментных регрессора; три режима маршрутизации. Вывод (честный отрицательный): ни один режим не обходит одиночную модель по общему MAE (baseline 522.5 против hard 609 / soft 563 / hybrid 527) — ошибки классификатора распространяются на регрессию. Полезен только soft routing для long-tail (long MAE 1693 против 1955) ценой small/normal.



режим	val MAE	Product	EngRisk	small	normal	long	test MAE
baseline_general	522.5	251.6	261.9	207.5	322.1	1955.5	429.3
cascade_hard	609.4	282.4	346.9	229.3	548.4	1946.3	474.4
cascade_soft	563.4	349.3	376.3	397.2	285.4	1693.3	470.1
cascade_hybrid	527.1	254.4	264.0	202.9	338.8	1962.5	430.2

12. Коррекция остатков базовой модели

Честная схема: base на блоке А → остатки на блоке В → компактный корректор; final = base + correction. Вывод: по общему MAE коррекция не помогает (522.5 → 528.6), но подтверждает систематику — корректор сдвигает прогноз вниз (−36 сек) и улучшает small_mae (207.5 → 186.7) ценой normal/long. Завышение коротких сессий реально есть, но глобально не «вычитается» из-за шума. Диагностика, не production-приём.

модель	val MAE	test MAE	small	normal	long	Product
base_only	522.5	429.3	207.5	322.1	1955.5	251.6
base_plus_correction	528.6	433.1	186.7	355.7	1987.1	252.1

13. LightGBM как альтернативный бустинг

Компактный случайный поиск (objective regression_l1 / quantile, n_estimators, lr, num_leaves, max_depth, fractions), категории — нативно через pandas category. Вывод: лучший LightGBM val MAE 524.7 / test 431.2 за ~2 с — сопоставим, но чуть хуже CatBoost (521.8 / 428.4), при этом CatBoost нативно работает с категориями и удобнее как единое семейство. Отказ от LightGBM — результат сравнения. Топ-8 по val MAE:

модель	objective	n_est	lr	leaves	val MAE	test MAE	fit, c
lgb12	regression_l1	1400	0.0	63	524.7	431.2	2.0
lgb09	regression_l1	1000	0.0	31	525.2	430.1	1.6
lgb13	regression_l1	1400	0.0	31	525.3	430.3	1.4
lgb03	regression_l1	1000	0.0	31	525.5	430.5	2.0
lgb00	regression_l1	1400	0.0	31	525.7	431.3	1.5
lgb10	quantile	600	0.0	31	525.7	429.8	1.7
lgb05	regression_l1	600	0.1	31	525.8	430.4	0.9
lgb08	quantile	1400	0.1	31	525.9	431.1	1.0

14. Ridge baseline vs Dummy (оба таргета)

Прозрачный L2-baseline против DummyRegressor(mean/median). Вывод: на next-session Ridge не обходит даже dummy_median (581 против 555 и 521.8 у CatBoost) — линейная модель почти бесполезна на этом шумном таргете. На CRM Ridge разумнее (test 331.8), но CatBoost всё равно сильнее (~272). Это и есть обоснование пользы нелинейных взаимодействий.


таргет	модель	val MAE	test MAE	R2	small MAE
target_next_session_length_sec	dummy_median	555.4	457.7	-0.1	196.6
target_next_session_length_sec	ridge_a100.0_p995	580.8	496.1	0.1	425.9
target_next_session_length_sec	ridge_a10.0_p995	581.1	496.4	0.1	425.2
target_next_session_length_sec	ridge_a1.0_p995	581.2	496.5	0.1	425.2
future_sessions_mean_playtime_7d	ridge_a100.0_p995	307.6	331.8	0.2	349.8
future_sessions_mean_playtime_7d	ridge_a10.0_p995	308.1	332.4	0.2	349.5
future_sessions_mean_playtime_7d	ridge_a1.0_p995	308.2	332.6	0.2	349.6

Часть III. Доработка: оба таргета, полные метрики, финальная модель

По итогам ревью добавлены блоки строго в технической зоне Участника 2 — для обоих таргетов (next-session и CRM) и с полным набором метрик (MAE, MedAE, P70, P90, R^2 , small/normal/long, ProductMAE, EngagementRiskMAE, WMAPE). Выбор везде по validation; калибраторы учатся на внутреннем calibration-split, test — только финальная оценка.

15. Анализ val-test разрыва

Почему val MAE (~522) хуже test MAE (~429) на next-session. Вывод: test-период объективно легче — доля long-сессий 0.122 против 0.158 в val, среднее 537 против 661 сек. Модель не подглядывает в test; разрыв объясняется составом периода. Для CRM, наоборот, val чуть легче test — и там val MAE < test.




таргет	split	n	mean	median	p90	long%	small%
target_next_session_length_sec	train	21000	676.6	302.0	1633.0	0.2	0.5
target_next_session_length_sec	val	4500	660.8	300.5	1705.1	0.2	0.5
target_next_session_length_sec	test	4500	537.3	234.5	1364.2	0.1	0.6
future_sessions_mean_playtime_7d	train	21000	596.2	469.0	1224.7	0.1	0.3
future_sessions_mean_playtime_7d	val	4500	554.8	448.7	1124.4	0.1	0.3
future_sessions_mean_playtime_7d	test	4500	597.3	489.4	1233.2	0.1	0.3

16. Time-aware history-признаки (оба таргета)

14 новых признаков из прошлой истории игрока (EWMA, медиана/среднее последних 3/5, тренд, время с прошлой сессии, активность за 1/3/7 дней) — строго past-only, без утечки. Вывод (по таргетам по-разному): на next-session history даёт маржинальный плюс (522.5 → 522.2, лучшие: ewma5, median_last5, time_since_prev) → включаем; на CRM history не помогает (238.7 → 238.9) → не включаем. Полный набор метрик в CSV.

History-признаки: val MAE (выбор по validation)



таргет	набор	k	val MAE	R2	Product	small	test MAE
target_next_session_length_sec	baseline	73	522.5	0.0	251.6	207.5	429.3
target_next_session_length_sec	baseline_plus_history	87	522.2	0.0	250.5	206.2	428.2
target_next_session_length_sec	baseline_plus_best_history	79	523.0	0.0	251.0	206.1	428.5
future_sessions_mean_playtime_7d	baseline	73	238.7	0.4	187.5	219.8	273.3
future_sessions_mean_playtime_7d	baseline_plus_history	87	238.9	0.4	188.1	222.4	272.2
future_sessions_mean_playtime_7d	baseline_plus_best_history	79	241.1	0.4	189.9	225.0	274.3

17. Regression calibration (оба таргета)

Пост-калибровка прогнозов: bin / isotonic / segment, калибратор на calibration-split. Вывод: калибровка улучшает long_mae и R^2 (next: long 1982→1608, R^2 0.01→0.10), но резко ухудшает small/normal и общий MAE (small 208→453), т.к. тянет прогноз к условному среднему, а MAE оптимизирует медиану. Для MAE-модели не включаем (выбор = raw) на обоих таргетах.

таргет	метод	val MAE	R2	Product	small	long	test MAE
target_next_session_length_sec	raw	521.1	0.0	251.1	208.4	1982.1	428.2
target_next_session_length_sec	bin	587.8	0.1	395.0	453.1	1621.7	502.6
target_next_session_length_sec	isotonic	581.3	0.1	390.1	446.6	1608.0	499.8
target_next_session_length_sec	segment	582.9	0.1	390.0	446.2	1627.8	499.7
future_sessions_mean_playtime_7d	raw	233.3	0.4	183.2	220.6	807.2	272.2
future_sessions_mean_playtime_7d	bin	248.3	0.4	199.8	252.5	800.2	286.2
future_sessions_mean_playtime_7d	isotonic	246.3	0.4	197.7	247.3	812.3	280.5
future_sessions_mean_playtime_7d	segment	246.2	0.4	197.7	247.3	801.0	281.3

18. Feature drift detection (оба таргета)


PSI (числовые) + доля новых категорий + сдвиг missing/среднего между train/test. Найдены drift-heavy признаки; проверены модели без top-5 / top-10 / strong-drift (PSI>0.25). Вывод: удаление нестабильных признаков сохраняется/выбирается только если не ухудшает validation MAE (решение записано для финальной сборки). Скоры по признакам — в drift_scores_<target>.csv.

таргет	вариант	k	drop	val MAE	test MAE
target_next_session_length_sec	all_features	87	0	522.2	428.2
target_next_session_length_sec	drop_top5_drift	82	5	522.3	429.3
target_next_session_length_sec	drop_top10_drift	77	10	523.0	428.6
target_next_session_length_sec	drop_strong_psi>0.25_n5	82	5	522.3	429.3
future_sessions_mean_playtime_7d	all_features	87	0	238.9	272.2
future_sessions_mean_playtime_7d	drop_top5_drift	82	5	240.7	273.6
future_sessions_mean_playtime_7d	drop_top10_drift	77	10	243.8	274.6
future_sessions_mean_playtime_7d	drop_strong_psi>0.25_n4	83	4	239.8	272.3

19. Финальная техническая модель (полные метрики, test)

Сборка лучших решений: гиперпараметры (best_by_mae из основного sweep), набор признаков (baseline + полезные history – drift-heavy), калибровка по решению блока 17. Обучена для обоих таргетов, сохранены артефакты (final_models/*.cbm, списки признаков, конфиг, README). Сравнение с обычным baseline:

Финальная модель vs baseline (test MAE)



таргет	модель	features	calib	MAE	MedAE	P90	R2	small
target_next_session_length_sec	baseline_reference	baseline	raw	428.4	206.2	997.4	0.0	185.8
target_next_session_length_sec	final	baseline+history	raw	428.4	206.1	998.1	0.0	181.2
future_sessions_mean_playtime_7d	baseline_reference	baseline	raw	273.3	160.0	645.0	0.3	253.3
future_sessions_mean_playtime_7d	final	baseline	raw	273.3	160.0	645.0	0.3	253.3

20. Итоговые рекомендации Участника 2

- 1. Архитектура. Перейти на `grow_policy=Depthwise`, `min_data_in_leaf=20`: тот же/лучший MAE при вдвое меньшей и более быстрой модели.
- 2. Признаки. Использовать SHAP-отбор 40 признаков вместо 73 — качество не падает, модель в ~3.5 раза компактнее, inference быстрее. Список сохранён в `feature_set_shap_40.json`.
- 3. Категории. Оставить простые CTR-настройки (`ctr_complexity=1`); комбинации категорий не оправданы.
- 4. Квантизация. Оставить дефолт `border_count=254`, `GreedyLogSum`.
- 5. Bootstrap. MVS не внедрять; при необходимости стабильности — Bayesian.
- 6. Стратегии. Для технической точности — `capped_target`; для short-risk (CRM/реклама) — `Quantile:alpha=0.35`.
- 7. Лучшая техническая модель (`best_by_mae`): CatBoost `depth=7`, `lr=0.03`, `l2=5`, `log1p_p995`, `Bernoulli` — val MAE 521.8 / test 428.4.
- 8. LightGBM сопоставим, но чуть хуже CatBoost и требует отдельной обработки категорий → остаётся на CatBoost (вывод по результату сравнения).
- 9. Каскад и коррекция остатков не улучшают общий MAE (ошибки классификатора / шум остатков), но полезны точечно: `soft-каскад` — для long-tail, корректор — как диагностика завышения коротких сессий.
- 10. Ridge не обходит median-baseline на next-session → нелинейный бустинг оправдан.
- 11. History-признаки включены в финал только для next-session (маржинальный плюс: `ewma5`, `median_last5`, `time_since_prev`); для CRM эффекта нет.
- 12. Calibration и удаление drift-признаков не включены — не улучшают validation MAE (калибровка полезна для long-tail/ R^2 , но ухудшает общий MAE и short-сегменты).
- 13. Финальная модель собрана и сохранена для обоих таргетов (`final_models/*.cbm` + конфиг/признаки/README); по MAE $\approx$ baseline — на шумных таргетах резерв качества лежит не в этих приёмах, а в самих данных/таргете.
- Оговорка. Все выводы по next-session ограничены высоким шумом таргета ($R^2 \approx 0.01$); приоритет архитектурных правок — компактность и скорость, а не точность.

Артефакты: `outputs/participant2_results.csv` (78 запусков в схеме протокола §16), per-experiment CSV, `anti_leak.json`, `best_base_config.json`, `feature_set_shap_40.json`. Воспроизводимость: `exp0...exp7.py`, `p2_common.py`.